

EP1

Clareza das respostas do e-SIC

Classificação em três classes: c1, c234 e c5

Prever quão clara o cidadão achou a resposta

Respostas de órgãos públicos a pedidos de acesso à informação, avaliadas pelo próprio usuário com nota de 1 a 5.

c1

Nota 1

6.347 respostas no treino

c234

Notas 2, 3 e 4 agrupadas

6.853 respostas no treino

c5

Nota 5

6.892 respostas no treino

20.092

respostas de treino

900

respostas de teste a rotular

101

palavras por resposta (mediana)

A nota mede satisfação, e tem ruído

291

dos 463 textos que se repetem no treino receberam notas diferentes.

A mesma resposta ganha notas distintas de usuários distintos: o teto de acurácia é baixo para qualquer modelo.

Negativas puxam para c1

Respostas que recusam o pedido (“não é possível”, sigilo, “não compete”) tendem a receber nota 1.

Curtas ou com anexo puxam para c5

Respostas diretas, ou que entregam um arquivo, tendem a receber nota 5.

Legibilidade quase não explica a nota

Flesch, tamanho de frase e palavras raras formam o grupo de atributos mais fraco: 39,5% sozinhos.

Todos os modelos nas mesmas divisões

1

Validação cruzada

5 dobras estratificadas sobre as 20.092 respostas. A mesma semente em todo o pipeline.

2

Holdout do professor

Divisão 80/20 estratificada, repetida como segunda checagem do resultado.

3

Baseline lado a lado

TF-IDF + regressão logística medido em cada dobra, junto com cada modelo.


34,3%

classe majoritária

45,54%

baseline oficial: a barra a superar

Quatro famílias de modelos, uma combinação



Diferença para o baseline na 1ª fase (dobras que agrupam textos idênticos; baseline = 44,56%). Também testados: Word2Vec, Doc2Vec, Naive Bayes, NB-SVM e, na 2ª fase, embeddings de sentença MiniLM e e5-small.

Nenhum modelo sozinho enxerga a resposta inteira

01

Sinais diferentes

Palavras, caracteres e significado capturam aspectos distintos do texto. Cada representação vê uma parte.

02

Erros diferentes

Quando os erros não coincidem, um modelo cobre a falha do outro, e a combinação supera cada parte.

03

Pesos aprendidos

Em vez de uma votação fixa, um meta-classificador aprende quanto confiar em cada modelo, classe a classe.

46,45%

melhor modelo isolado (TF-IDF + SVM)



46,98%

stacking dos quatro modelos

Mesmas dobras. O meta aprende com previsões feitas em respostas que cada modelo-base não viu no treino.

Quatro modelos-base, cada um com um papel

lr_pal

Regressão logística · TF-IDF de palavras (1-2-gramas)

Capta expressões decisivas para a nota, como “não é possível” e “segue em anexo”. É a base mais forte.

svc

LinearSVC · TF-IDF de palavras + caracteres (2-5)

Os caracteres pegam flexões, siglas e grafias variadas; com outra fronteira de decisão, erra em outros lugares.

emb_minilm

Regressão logística · embeddings de sentença MiniLM

Traz o significado: aproxima respostas que dizem o mesmo com palavras diferentes, o que o TF-IDF não vê.

extremos

Classificador $c1 \times c5$, treinado só nos extremos

Cria um eixo contínuo “ruim-bom”: quem cai no meio dele ajuda a reconhecer a c234, a classe mais difícil.

4 modelos-base



Meta-classificador: regressão logística (C = 0,1)



c1 · c234 · c5


Acima do baseline nas cinco dobras

acurácia média • 5 dobras

46,98%

+1,44 pp sobre o baseline
oficial (45,54%)

Holdout 80/20 do professor:
47,70% contra 46,75% do baseline



A classe do meio é a mais difícil

Matriz de confusão • % de cada classe real • 20.092 previsões fora da dobra

prev. c1	prev. c234	prev. c5	real c1
51,3% 3.255	25,1% 1.595	23,6% 1.497	real c234
30,9% 2.121	32,3% 2.212	36,8% 2.520	real c5
18,7% 1.289	23,7% 1.631	57,6% 3.972	

c234 cai mais em c5 que em si mesma

Uma resposta nota 2–4 vai mais para c5 (36,8%) do que para a própria classe (32,3%): as notas do meio se espalham entre as vizinhas.

Os extremos são mais fáceis

c5 acerta 57,6% e c1, 51,3%. O bloco **extremos** existe para explorar esse eixo “ruim–bom”.

Contra o baseline

O modelo acerta 1.546 respostas que o baseline erra; o baseline acerta 1.257 que o modelo erra.

O que aprendemos

O teto da tarefa é baixo

Até respostas idênticas recebem notas diferentes: boa parte da nota não está no texto.

Representações se completam

Palavras, caracteres, significado e o eixo “ruim-bom”: cada bloco traz um sinal que os outros não têm.

A combinação supera as partes

O stacking passa o melhor modelo isolado e vence o baseline nas cinco dobras e no holdout.

Comparação justa

Mesmas dobras e mesma semente para todos os modelos, com o baseline medido lado a lado.

ENTREGA Teste rotulado pelo modelo final (294 c1 · 264 c234 · 342 c5), reproduzível com um único script.